

Modelar la lluvia semanal del Valle del Cauca y medir cuánto aporta la correlación espacial

Regresión sobre posición y relieve + kriging del
residuo — kriging universal — programado en R
base con **terra** para leer los rásteres.

INTEGRANTES


César A. Reyes Oliveros
Yesenia Díaz
Juan Pablo Maya

DATOS

CHIRPS · NASA POWER ·
SRTM
Grilla 0,05° · EPSG:4326
688 celdas · 70
estaciones

PROFESOR

Johann A. Ospina
Juan-maya935/
Proyecto1_Analitico



● PROBLEMA

Tres climas en 150 km. La pregunta no es **predecir lluvia**: es cuánto queda en el residuo **después** de una buena regresión.

Vertiente pacífica, valle interandino y dos cordilleras: el banco de pruebas ideal para la correlación espacial.

La costa supera los **200 mm/semana**; el valle se queda en **30–50 mm**. Un factor de 5 a 7 en unos 150 km: efecto orográfico clásico, la masa húmeda del Pacífico descarga contra la cordillera Occidental.

Estrategia: kriging universal. Separar la lluvia en una **deriva determinística** (posición + altitud) y un **residuo espacialmente correlacionado** que se interpola con kriging ordinario.

$$Z(s) = m(s) + \varepsilon(s)$$

$$m(s) = \beta_0 + \beta_1 \cdot x + \beta_2 \cdot y + \beta_3 \cdot \text{altitud} (+ \beta_4 \cdot x^2)$$




Fig. 3 Precipitación semana 44 (mm) recortada al límite GADM del departamento

Auditar el dato antes de modelarlo, y elegir el momento donde la señal espacial es más fuerte.

Tres arreglos que el enunciado no advertía, una semana elegida con criterio, y el kriging universal desarmado en seis pasos.

688

CELDA S REALES

-76 867

CENTINELA CHIRPS

S44

SEMANA MÁS LLUVIOSA

Antes de modelar hubo que arreglar tres cosas que el enunciado **no** advertía.

- **Valores centinela.** CHIRPS codifica vacíos como **-76 867,3** en 104 celdas. Filtro $r[r < 0] \leftarrow NA$ → mínimo físico 2,77 mm.
- **El rectángulo no es el departamento.** 1 443 píxeles incluyen océano y vecinos. Enmascarando con altitud y lluvia quedan **688 celdas**: ese es el denominador.
- **Cobertura real de covariables.** NASA POWER es 0,5° (10× más grueso). El remuestreo no rellenó huecos: la radiación deja **3 valores** para todo el Valle.


Modelo con **altitud + coordenadas**: cobertura completa, ningún dato inventado.

VARIABLE	CELDAS	% ÁREA	DISTINTOS	DECISIÓN
Precipitación · CHIRPS	688	100,0	688	respuesta
Altitud · SRTM	688	100,0	688	entra
Temperatura · POWER	123	17,9	56	se descarta
Radiación · POWER	28	4,1	3	se descarta

Tabla 1 · porcentaje sobre las 688 celdas del área de estudio. Medido contra las 1 443 del rectángulo la altitud “cubría” 47,7 % y se habría descartado por error.



Se trabaja la **semana 44** de la climatología 2010–2025: la más lluviosa, donde la señal espacial es más fuerte.



91,9 mm

SEMANA 44 • MÁXIMO


28,7 mm

SEMANA 3 • VERANILLO DE ENERO

Por qué la climatología y no un año suelto: al promediar 16 años, El Niño y La Niña dejan de meterse en el residuo, que es justo lo que después modela el semivariograma. Sobre un año concreto el rango estimado dejaría de ser interpretable.

Fig. 1 Ciclo anual promedio. Régimen bimodal: la firma del doble paso de la ZCIT sobre el departamento

El método completo en seis pasos, sobre los datos del proyecto.



1 Deriva · MCO

$$\hat{\beta} = (X^T X)^{-1} X^T Z \cdot \text{residuo } \varepsilon = Z - X\hat{\beta}$$

2 ¿Hay estructura?

Moran I y Geary C sobre ε · 999 permutaciones

3 Cuánta y hasta dónde

Semivariograma $\gamma(h)$ + esférico / exponencial / gaussiano

4 Kriging ordinario

$$\sum \lambda_j C(s_i - s_j) + \mu = C(s_i - s_0) \cdot \sum \lambda_j = 1$$

5 Predicción

$$\hat{Z}(s_0) = \hat{m}(s_0) + \varepsilon(s_0)$$

6 Validación LOOCV

RMSE · MAE · R^2 · sd(z) del error estandarizado

Fig. 2 Dato → deriva → residuo → Moran → semivariograma → pesos de kriging

70 estaciones sorteadas, 2 415 pares. La lluvia es **muy asimétrica**... pero la pregunta correcta es si lo son los residuales.




Tabla 2 Precipitación en las 70 estaciones · semana 44 · Shapiro-Wilk W = 0,816, p = 6,4e-08

MÍN	Q1	MEDIANA	MEDIA	Q3	MÁX	CV
34,9	51,7	64,2	91,1	125,9	189,0	56 %

Media 42 % por encima de la mediana. De Q1 a mediana 12 mm; de mediana a Q3, 62 mm. La cola larga es la vertiente **pacífica**.

COVARIABLE	R PEARSON	LECTURA
Longitud (x, km)	-0,890	sola explica el 79 % de la varianza
Altitud (m)	-0,651	fuerte en apariencia — confundida
Latitud (y, km)	-0,274	aporte marginal

Por qué 70 y no 688: el kriging invierte una matriz de orden n+1 por celda y por iteración; y con las 688 celdas ya no queda nada que interpolar. El muestreo simula una red de observación.

Lo que la regresión explica, y lo que deja **agrupado en manchas** sobre el mapa.

Una confusión que cambia el signo de la altitud,
residuales que sí son normales, y un índice de Moran que
dice que la regresión sola deja información sobre la mesa.

84 %

VARIANZA · REGRESIÓN

+0,0098

ALTITUD · SIGNO INVERTIDO

0,793

MORAN I · RESIDUALES

La altitud parecía **secar** el territorio. Controlando la posición, **lo humedece**: un caso de manual de confusión.




Fig. 4a Estratificado por longitud: oeste -0,058 · centro +0,017 · este +0,005 mm/m




Fig. 4b Variable añadida: la pendiente +0,0098 es el coeficiente del modelo

COEF. MODELO B	EST.	P
Intercepto	79,50	<0,0001
x_km	-1,161	<0,0001
y_km	+0,317	<0,0001
altitud	+0,0098	0,0317

$R^2 = 0,845$ (aj. 0,838). Test F anidado A vs B: $F = 4,82$, $p = 0,032 \rightarrow$ **la altitud se queda**.

Correlación altitud-longitud = 0,755: la costa es baja y occidental, la cordillera alta y oriental. “Más alto, menos lluvia” decía en realidad **“más al oriente, menos lluvia”**.

Quitada la deriva, los residuales **sí son normales**. Pero dibujan una U y forman manchas: la recta está mal especificada.





Fig. 5 Residuales del modelo B: histograma · Q-Q · residual vs ajustado (la U)

SERIE	SD (MM)	SHAPIRO W	P	CONCLUSIÓN
Precipitación cruda	51,32	0,816	6,4e-08	no normal
Residuales modelo B	20,21	0,975	0,174	normal



rojo · subestima azul · sobreestima

La asimetría era la tendencia, no la distribución: **no hacía falta el logaritmo**. Y la U (ajustado $\approx 100 \rightarrow$ residual -40) anticipa un término cuadrático.

Después de que la regresión se llevó el 84 % de la varianza, lo que sobra **sigue teniendo estructura espacial fuerte.**





Fig. 6a Diagrama de Moran: la pendiente de la recta es I · rojo alto-alto · azul bajo-bajo

0,793		-0,014		0,001	
MORAN I · RESID. · 20 KM		ESPERADO BAJO AZAR		P · 999 PERMUTACIONES	
PCTL	UMBRAL KM	VECINOS	I PRECIP.	I RESID.	C RESID.
5	19,7	3,5	0,955	0,793	0,187
10	28,0	6,9	0,938	0,722	0,275
25	48,5	17,3	0,812	0,460	0,540

Moran y Geary programados a mano con la fórmula de clase. Tres umbrales, no uno, porque el umbral cambia el número. I alto y C bajo en los tres: **la regresión deja información espacial sobre la mesa.** Ese hueco lo llena el kriging.

No decae a cero y se queda ahí: es una **onda**. Y esa onda fija el corte del semivariograma en 50 km.





- 0–48 km · I de +0,79 a 0. Dependencia espacial genuina; anticipa el rango del semivariograma.
- ≈89 km · I = -0,54. Media anchura del departamento: el azul del centro del valle contra el rojo de un flanco.
- ≈149 km · I = +0,51. Los dos flancos se reencuentran; ambos rojos.

El lóbulo negativo dice que los residuales no son estacionarios de segundo orden a gran distancia: queda estructura determinística.

Los modelos de semivariograma asumen crecimiento monótono hasta una meseta, y eso solo se cumple hasta ~50 km. El libro del curso respalda limitar la distancia máxima “en caso de comportamiento errático a distancias mayores”.

Fig. 6b I de Moran por distancia · línea roja: E[I] bajo aleatoriedad

Tendencia lineal vs cuadrática: la decisión deja de ser preferencia y pasa a ser **evidencia**. La meseta debe aproximar la varianza.



TEND.	MODELO	MESETA	VAR.	RAZÓN
cuad.	esférico	161,7	158,8	1,02
cuad.	gaussiano	152,9	158,8	0,96
cuad.	exponencial	285,6	158,8	1,80
lineal	gaussiano	537,6	408,4	1,32
lineal	esférico	769,6	408,4	1,88
lineal	exponencial	1275,1	408,4	3,12

Tabla 7 · corte a 50 km · ajuste por mínimos cuadrados con optim() y varios arranques. La lineal falla en 3 de 3; la cuadrática es coherente en 2 de 3.

lineal sube sin meseta, cruza la varianza

cuadrática meseta sobre la varianza a ~40 km

Elegir con tres filtros, no con el menor error. Y reconstruir el mapa completo desde 70 puntos.

Leave-one-out sobre seis combinaciones, dos trampas que el RMSE no ve, y la respuesta gráfica al enunciado: lo que aporta la tendencia y lo que agrega el kriging.

-37%

RMSE CON KRIGING

0,950

R^2 · 620 CELDAS NO VISTAS

1,06

SD(Z) · CALIBRACIÓN

El menor RMSE **no** es la mejor opción.
Se eligió con tres filtros a la vez;
exactamente una combinación los pasa.

TEND.	MODELO	RMSE SIN KRIG.	RMSE CON KRIG.	MEJORA	R ² CV	SD(Z)	K(A)
lineal	exponencial	21,32	7,09	66,7 %	0,981	0,69	7,7e6
lineal	esférico	21,32	7,15	66,5 %	0,980	0,73	1,1e6
cuadrática	exponencial	14,02	8,72	37,8 %	0,971	1,01	1,7e5
cuadrática	esférico	14,02	8,86	36,8 %	0,970	1,06	1,0e4
cuadrática	gaussiano	14,02	23,16	-65,3 %	0,793	18,61	1,2e5
lineal	gaussiano	21,32	160,29	-651,9 %	-8,897	339,0	1,2e8

Tabla 8 · 70 iteraciones por fila, reestimando regresión y sistema de kriging con 69 estaciones. sd(z) ≈ 1 si la varianza de kriging es creíble. κ(A): número de condición de la matriz.

- 1

Estacionariedad

meseta / varianza ≈ 1, según el libro
- 2

Calibración

sd(z) entre 0,80 y 1,25, o el mapa de incertidumbre no significa nada
- 3

Estabilidad

κ(A) acotado, para que los pesos no exploten

Dos trampas. El gaussiano ajusta muy bien el variograma y destroza la predicción (autovalor mínimo 0,0086 vs 9,13 del esférico). Lineal+exponencial baja a 7,09 mm, pero su meseta triplica la varianza y su sd(z) = 0,69 exageraría la precisión un 45 %.

Tendencia cuadrática + semivariograma esférico. Pepita 0, meseta 161,7 mm², rango **56,1 km**.




Fig. 8a Observado vs predicho · residuos de validación · Q-Q del error estandarizado




Fig. 8b Error L00CV: ya no forma manchas

-37%

RMSE · 14,02 → 8,86 MM

0,970

R²
VALIDACIÓN

5,53

MAE MM

1,06


SD(Z)

1e4

K(A)

La mejora sale **solo** de explotar la correlación del residuo, sin ninguna variable nueva. El kriging absorbió la estructura que la regresión dejó suelta.

Reconstruir el mapa completo desde 70 puntos: $R^2 = 0,950$ en las 620 celdas que nunca se observaron.



CONJUNTO	CELDAS	RMSE	R ²
LOOCV estaciones	70	8,86	0,970
Celdas sin estación	620	10,79	0,950
Celdas con estación	68	2,09	—

El número honesto es el de las 620 celdas. Rango observado 34,9–224,8 mm; predicho 34,6–223,2. Media 88,9 vs 90,1 observada: sesgo –1,4 %, despreciable frente al error.

Los 2,09 mm en celdas con estación **no se celebran**: con pepita 0 el kriging interpola exacto en los puntos observados. Mide una propiedad del método, no su capacidad predictiva.

Fig. 9 Observado vs estimado, misma escala. El estimado es algo más suave: lo esperado de un interpolador óptimo en media cuadrática

El panel B no es ruido: tiene estructura organizada. **Eso** es el papel de la correlación espacial que había que evaluar.




Fig. 10a sd de kriging (mm)




Fig. 10b (A) lo que aporta la tendencia • (B) lo que agrega el kriging del residuo

1,1 mm

SD MÍNIMA • SOBRE ESTACIONES

12,6 mm

SD MÁXIMA • FILO ORIENTAL, PUNTA NORTE

La incertidumbre se comporta como manda la teoría: crece con la distancia al dato más cercano. Este mapa **solo es legible porque $sd(z) = 1,06$** ; con el modelo de menor RMSE habría exagerado la precisión.

La correlación espacial no es un adorno del modelo: **es la mitad del modelo.**

84 %

VARIANZA · REGRESIÓN

0,79

MORAN I RESIDUAL · P 0,001

-37 %

ERROR CON KRIGING

0,950

R² · 620 CELDAS NO VISTAS

1

La altitud no seca: humedece

Sola, $r = -0,651$. Controlando longitud, $+0,0098$ mm/m. La conclusión ingenua es exactamente la contraria de la que sostiene el modelo.

2

Ajustar mejor el variograma no es predecir mejor

El gaussiano pega muy bien a la nube empírica y da $R^2 = -8,9$ en validación: matriz casi singular, pesos que explotan.

3

El menor RMSE no siempre es la mejor decisión

Lineal+exponencial baja a 7,09 mm, pero es no estacionario y mal calibrado: habría producido un mapa de incertidumbre engañoso.

Cuatro cosas que este trabajo **asume** y prefiere decir.

Producto grillado, no estaciones reales

Las 688 celdas vienen de CHIRPS. El R^2 mide capacidad de reconstruir ese campo, no destreza frente a observaciones independientes.

El efecto de la altitud no es homogéneo

Negativo en la vertiente pacífica, positivo en laderas interiores. Lo correcto sería una interacción altitud $\times$ longitud; se omitió por quedarse en lo visto en clase.

No estacionariedad más allá de ~50 km

El correlograma obligó a cortar el variograma y deja fuera la estructura de gran escala restante.

Una sola semana

La 44 es la más lluviosa del año promedio; los parámetros del variograma podrían cambiar en temporada seca.

● REPOSITORIO

github.com/Juan-maya935/Proyecto1_Analitico

R/proyecto1.R · un archivo reproducible · terra + R base · 27 figuras en resultados/